

Projectnaam: Cornetto: Combinatorial and Relational Network as Toolkit for Dutch Language Technology

Projectnummer: STE05039

Rapporteringsperiode: 1 april 2006 – 30 september 2006

Deelnemers: Vrije Universiteit, Amsterdam, Faculteit der Letteren (VU-AMS)
Universiteit van Amsterdam, Instituut voor Informatica (UVA-AMS)
K.U. Leuven- ICRI (KU-LEU)
Irion Technologies B.V. (IRION)

Uitvoerders van het onderzoek:

- Piek Vossen (VU-AMS/IRION)
- Willy Martin (VU-AMS)
- Hennie van der Vliet (VU-AMS)
- Isa Maks (VU-AMS)
- Roxane Segers (VU-AMS)
- Maarten de Rijke (UVA-AMS)
- Erik Tjong Kim Sang (UVA-AMS)
- Katja Hofmann (UVA-AMS)
- Marie-Francine Moens (KU-LEU)
- Hetty van Zutphen (IRION)
- Elton Glaser (IRION)
- Joop van Gent (IRION)
- Mihaela Gradinaru (IRION)
- Agata Cybulska (IRION)

1 Samenvatting

1.1 Deliverables (+tijdstip) volgens projectvoorstel

In onderstaande tabel worden de deliverables gegeven met gerelateerde workpackages, de opleverdatum en de status. De nummering komt overeen met bijlage-4 uit het consortiumagreement.

Table 1: Deliverables

Id	Wp	Title	opleverdatum	status	Mo.
	0	project management en rapportering	doorlopend	in progress	
D01	1	MEANING-Cornetto Database	30/09/06	in progress	6
D02	2	Aligned RBN, DWN and Wordnet2.x	30/09/06	in progress	6
D03	3	Top-level ontology, relation constraints and assignments	31/12/06	in progress	9
D04	4	Core Cornetto	30/07/07	in progress	15
D05	4	Extended Cornetto	31/01/08	nog niet gestart	22
D06	5	Acquired concepts	30/03/07	nog niet gestart	12
D07	5	Acquired relations	30/07/07	nog niet gestart	15
D08	5	Cornetto Acquisition toolkit	30/07/07	in progress	15
D09	6	Ontology for the legal and finance domain	30/03/07	in progress	12
D10	6	Sub-database tuned, trimmed and extended to the legal and finance domain	31/01/08	nog niet gestart	22
D11	6	Domain tuning toolkit	31/01/08	nog niet gestart	22
D12	7	Evaluation report of the ontology advisory-board	30/03/07	in progress	12
D13	7	Task-based evaluation of Core Cornetto	30/09/07	in progress	17
D14	7	Task-based evaluation of Extended Cornetto	31/01/08	nog niet gestart	22
D15	7	Evaluation report of the user-group on the legal and finance sub-database	31/01/08	in progress	22
D16	8	Final Cornetto database and software	30/03/08	in progress	24

1.2 Reeds eerder afgemaakte deliverables

Er zijn geen eerder afgemaakte deliverables, wel is de licentieovereenkomst die onderdeel maakt van D16 (opleverdatum: 30/03/08) in samenwerking met de TST-centrale opgesteld en goedgekeurd door de betrokken partijen.

1.3 Gewenste wijzigingen (inhoud/tijdstip van deliverables)

De oplevering van de database (WP1, D01) en de alignment (WP2, D02) heeft enige weken vertraging opgelopen. De oplevering van beide is nu verschoven van 30/09/2006 naar 31/10/2006. De documentatie zal spoedig daarna beschikbaar komen. Onder 2.1 zal dit nader worden toegelicht. Hier staat tegenover dat we eerder begonnen zijn met WP3, WP4 en WP7.

1.4 De personeelsinzet in relatie tot het oorspronkelijke plan

partner	Voorzien aantal mensmaanden hele project	Aantal mensmaanden uitgevoerd periode 1	Totaal aantal uitgevoerde mensmaanden
VU-AMS	18	0 (3)	0(3)
UVA-AMS	15	3(5.2)	3(5.2)
KU-LEU	14	0 (0.13)	0 (0.13)
IRION	10	6 (8)	6(8)
Totaal	57		

Opmerking: de cijfers tussen haakjes geven het aantal mensmaanden, inclusief de niet door het project betaalde inzet (pro-memorie). De cijfers die niet tussen haakjes staan, slaan op de door het project betaalde inzet.

1.5 Disseminatie van resultaten (publicaties, lezingen....)

Voor de interne communicatie is er een TWIKI site opgezet bij de UVA. Deze site bevat alle tussentijdse resultaten, discussiestukken, verslagen van projectvergaderingen en technische vergaderingen, publicaties en presentaties. Op aanvraag kunnen alle documenten en informatie van die site aan de NTU worden overgedragen.

Verder is er een publieke website opgericht bij de VU
<http://www.let.vu.nl/onderzoek/projectsites/cornetto/start.htm>

Op de Stevin-programmadag (d.d. 11-september-2006, Antwerpen) is het project gepresenteerd en naar aanleiding daarvan zijn er afspraken gemaakt om met het team van het Stevinproject IRME samen te werken m.b.t. de representatie van meerwoordsuitdrukkingen in beide lexica.

Tenslotte is er overleg geweest over een mogelijke samenwerking tussen Cornetto en een SemEval-2007 voorstel waarin een taakgebaseerde evaluatie van WSD wordt opgezet. Mogelijkerwijs zou een deel van de evaluatie van Cornetto binnen dat raamwerk kunnen worden uitgevoerd. Op dit moment wordt de evaluatie in SemEval 2007 alleen voor het Engels opgezet. Voor Cornetto zou dit moeten worden uitgebreid naar het Nederlands.

Op dit ogenblik zijn er nog geen publikaties i.v.m. het project.

2 Vorderingen per deliverable

2.1 Gerealiseerde werkzaamheden in afgelopen periode

WP0: Management

In de eerste periode hebben we 2 algemene projectbijeenkomsten gehad:

- 10 maart 2006, VU, Amsterdam
- 27 juni 2006, VU Amsterdam

Daarnaast zijn er vele technische bijeenkomsten geweest tussen de projectpartners. De volgende projectbijeenkomsten staan gepland op 12 oktober 2006 en 5 januari 2007.

In de eerste bijeenkomsten zijn afspraken gemaakt over de projectcommunicatie. Er is een TWIKI site opgesteld bij de UVA-AMS en een publieke website bij de VU-AMS. Verder hebben we emaillijsten ingesteld.

Het consortiumagreement is opgesteld, inclusief de licentieovereenkomsten voor de eindresultaten, en door alle betrokkenen getekend. Een kopie van het consortiumagreement is verstuurd naar het Stevinprogrammabureau. De licentieovereenkomst is opgesteld in samenwerking met de TST-centrale. Van Dale en de Universiteit van Amsterdam hebben ingestemd en het wachten is op de definitieve getekende exemplaren.

WP1: Cornetto database

Database ontwerp:

- data structuren
- inhoudsdefinities
- edit handelingen en logging
- Samenwerking met IRME over meerwoordsuitdrukkingen.

Dataconversies:

- import van SUMO
- import van WordNet domains
- conversie van WN 1.5 en 1.6 equivalentie relaties naar WN 2.0 equivalentie relaties
- Nederlandse wordnet naar Cornetto formaat
- RBN naar Cornetto format

Database implementatie van servers and clients

WP2: Aligning semantic resources

- Van Synsets naar Lexical Units: de bestaande software voor de alignment van wordnets gaat uit van synsetstructuren. Het RBN is echter gestructureerd als een lijst van lexicale units (LUs) en bevat geen synsets. In eerste instantie is geprobeerd om de LUs om te vormen tot synsets en daarna de bestaande machinerie te gebruiken. Die synsets bleken echter niet van voldoende kwaliteit om te kunnen worden gebruikt. Daarom is er besloten om de alignmentmodule aan te passen zodat met LUs gewerkt kan worden. Dit betekent ook dat het Nederlandse wordnet moest worden omgezet van een Synset naar een LU structuur en nieuwe databases moesten worden gemaakt. Deze extra werkzaamheden hebben tot een maand vertraging geleid. Bovendien kunnen een aantal heuristieken die betrekking hebben op de synsetstructuur niet worden gebruikt. Daar staat tegenover dat is gebleken dat de semantische informatie en ook de betekenisindeling van het DWN en RBN erg compatibel lijken te zijn. We hebben daarom goede hoop dat op grond van die informatie de alingment succesvol zal zijn.
- Nieuwe heuristieken voor de alignment van lexical units in plaats van synsets zijn ontwikkeld.
- De domeininformatie in het DWN en RBN is op elkaar afgebeeld.
- Voortijdige alignment (null-alignment) heeft plaatsgevonden voor het testen van de database en het bekijken van de koppelingen. Deze alignment is alleen gebaseerd op het betekenisvolgnummer van beide bronnen.

WP3: Ontologize

- Studie van beschikbare ontologieën.
- Discussie met SUMO ontwikkelaars over verschillen SUMO-WordNet en DWN.
- Een methode voor de werkwijze is ontworpen, gegeven de edit-mogelijkheden van de database. Deze methode is opgenomen in de editor guide opgesteld in WP4.

WP4: Cornetto editing

- Er is een eerste versie van een Editor Guide (versie 1.0).
- Er zijn WIKI-logs gemaakt voor het registreren van alle ervaringen en besluiten tijdens het editen. Deze ervaringen worden gebruikt om de algemene Editor Guide aan te passen.

- Droogzwemmen: het bekijken van de data en bespreken van de noodzakelijke wijzigingen op papier.
- Studie van beschikbare documentatie en materialen.

WP5: Acquisition toolkit

- Planning van het werk, literatuuronderzoek en implementatie van een eerste versie van de toolkit.

WP6: Domain acquisition

- Nog niet gestart.

WP7: Evaluation

- Gebruikersscenario's.
- Samenwerking met SemEval-2007.

WP8: Distribution

- Licenties voor de distributie van de materialen zijn klaar en goedgekeurd door de betrokkenen.

2.2 Knelpunten en oplossingen

- Geen knelpunten

2.3 Voorgestelde planning voor de komende periode

WP1: Cornetto database

- Afronding, verder werk en ondersteuning: zodra de database intensief gebruikt gaat worden zal verwachten we dat verder aanpassingen nodig zijn.
- Zodra de documentatie voor de database is afgerond, zal deze worden gepubliceerd op de publieke website en worden rondgestuurd naar de ontologiegroep en de gebruikersgroep in het project. De te verwachten feedback zal worden gebruikt om eventuele verbeteringen uit te voeren.

WP2: Aligning semantic resources

- Afronding van de implementatie, iken van de heuristieken en definitieve export van de data
- Beschrijven van de methodes, de kwaliteit en het eindresultaat

WP3: Ontologize

- Keuze voor de definitieve ontologie
- Het definieren van een KIF representatie voor expressies
- Top-down ontologiseren van de synsets

WP4: Cornetto editing

- Verder ontwikkelen van de Editor Guide
- Testen van de database clients
- Definieren van een structuur voor meerwoordsuitdrukkingen
- Definieren van selecties om het werk te prioriteren en te verdelen
- Daadwerkelijk editen van de data

WP5: Acquisition toolkit

- Uitbreiding en evaluatie van de toolkit alsmede presentatie van het werk in conferenties.
- Selecteren van relevante ontologie in het financiële, juridische domein (onderzoeken van bestaande ontologieën).
- Verzamelen en verwerken (preprocessen, natural language processing) van relevante corpora.
- Scenario's:
 - Binnen het project AMASS++ (Advanced Multimedia Alignment and Structured Summarization) cross-document coreferentieresolutie van zelfstandige naamwoordgroepen, semantische roldetectie, herkennen van visuele attributen, herkennen van visuele acties
 - Binnen het project ACILA (Automatic Detection and Classification of the Arguments of a Legal Case) kunnen we een test uitvoeren of CORNETTO bijdraagt tot een betere classificatie van de argumenten in een juridische Nederlandstalige casus.

Deze evaluaties willen we uitvoeren bijvoorbeeld begin 2008. ACILA is pas oktober 2006 van start gegaan. AMASS++ gaat januari 2007 van start. Dit zijn onze enige projecten waar we Nederlandstalige teksten verwerken.)

WP6: Domain acquisition

- Uitwerken van cases en opbouwen van de tekstcorpora.

WP7: Evaluation

- Begin November wordt een eerste beschrijving van de gebruikersscenario's gecompileerd met input van UVA-AMS, KU-LEU en IRION. Op de projectbijeenkomst van januari 2007 zal worden besloten hoe we evaluatie rond die scenario's verder gaan opzetten. Rond de helft van het project (voorjaar 2007) wordt verwacht dat we tenminste een van de evaluaties kunnen uitvoeren.
- Op 30 November is er een presentatie gepland voor de TST-dag te Rotterdam.

WP8: Distribution

- Teken van de licentiecontracten