

Projectnaam: Cornetto: Combinatorial and Relational Network as Toolkit for Dutch Language Technology

Projectnummer: STE05039

Rapporteringsperiode: 1 oktober 2006 – 30 maart 2007

Deelnemers: Vrije Universiteit, Amsterdam, Faculteit der Letteren (VU-AMS)
Universiteit van Amsterdam, Instituut voor Informatica (UVA-AMS)
K.U. Leuven- ICRI (KU-LEU)
Irion Technologies B.V. (IRION)

Uitvoerders van het onderzoek:

- Piek Vossen (VU-AMS/IRION)
- Willy Martin (VU-AMS)
- Hennie van der Vliet (VU-AMS)
- Isa Maks (VU-AMS)
- Roxane Segers (VU-AMS)
- Maarten de Rijke (UVA-AMS)
- Erik Tjong Kim Sang (UVA-AMS)
- Katja Hofmann (UVA-AMS)
- Marie-Francine Moens (KU-LEU)
- Hetty van Zutphen (IRION)
- Elton Glaser (IRION)
- Joop van Gent (IRION)
- Mihaela Gradinaru (IRION)
- Agata Cybulska (IRION)

1 Samenvatting

1.1 Deliverables (+tijdstip) volgens projectvoorstel

In onderstaande tabel worden de deliverables gegeven met gerelateerde workpackages, de opleverdatum en de status. De nummering komt overeen met bijlage-4 uit het consortiumagreement.

Table 1: Deliverables

Id	Wp	Title	opleverdatum	status	Mo.
	0	project management en rapportering	doorlopend	in progress	
D01	1	Cornetto Database	30/09/06	done	6
D02	2	Aligned RBN, DWN and Wordnet2.x	30/09/06	done	6
D03	3	Top-level ontology, relation constraints and assignments	31/12/06	in progress	9
D04	4	Core Cornetto	30/07/07	in progress	15
D05	4	Extended Cornetto	31/01/08	nog niet gestart	22
D06	5	Acquired concepts	30/03/07	in progress	12
D07	5	Acquired relations	30/07/07	in progress	15
D08	5	Cornetto Acquisition toolkit	30/07/07	in progress	15
D09	6	Ontology for the legal and finance domain	30/03/07	in progress	12
D10	6	Sub-database tuned, trimmed and extended to the legal and finance domain	31/01/08	nog niet gestart	22
D11	6	Domain tuning toolkit	31/01/08	nog niet gestart	22
D12	7	Evaluation report of the ontology advisory-board	30/03/07	in progress	12
D13	7	Task-based evaluation of Core Cornetto	30/09/07	in progress	17
D14	7	Task-based evaluation of Extended Cornetto	31/01/08	nog niet gestart	22
D15	7	Evaluation report of the user-group on the legal and finance sub-database	31/01/08	in progress	22
D16	8	Final Cornetto database and software	30/03/08	in progress	24

1.2 Reeds eerder afgemaakte deliverables

Er zijn geen eerder afgemaakte deliverables.

1.3 Gewenste wijzigingen (inhoud/tijdstip van deliverables)

De oplevering van de database (WP1, D01) heeft in periode twee plaatsgevonden. Er deden zich meer problemen voor dan voorzien met de ontwikkeling van de database. Stabiliteit en performance van de clients en servers waren de grootste factor. Daarbij speelde ook een rol dat de structuur van de data een aantal keren is aangepast naar aanleiding van voortschrijdend inzicht.

1.4 De personeelsinzet in relatie tot het oorspronkelijke plan

partner	Voorzien aantal mensmaanden hele project	Aantal mensmaanden uitgevoerd periode 2	Totaal aantal uitgevoerde mensmaanden
VU-AMS	18	6 (9)	6(9)+
UVA-AMS	15	5 (6.7)	8(11.9)+
KU-LEU	14	4 (0.2)	4 (0.33)+
IRION	10	3 (5)	9(13)+
Totaal	57		

Opmerking: de cijfers tussen haakjes geven het aantal mensmaanden, inclusief de niet door het project betaalde inzet (pro-memorie). De cijfers die niet tussen haakjes staan, slaan op de door het project betaalde inzet.

De K.U.Leuven beschikt in het CORNETTO project over een bedrag voor personeel dat toelaat voor ca. 9 persoonsmaanden een postdoc researcher of voor ca. 11-12 persoonsmaanden een onderzoeker aan te werven. De aard van het werk vereist dat de aan te werven persoon het Nederlands goed beheerst. De K.U.Leuven is er tot nu toe nog niet in geslaagd een geschikte kandidaat te vinden voor dergelijk kort arbeidscontract, ondanks affichering via talrijke kanalen. De K.U.Leuven hoopt deze zomer onder de studenten die afstuderen een kandidaat te vinden.

Het gevolg is dat het projectaandeel van de K.U.Leuven vertraging oploopt en dat de K.U.Leuven 2 deliverables (domain corpus en domain ontology) nog niet heeft kunnen opleveren. Deze vertraging brengt de oplevering van andere deliverables van CORNETTO niet in gevaar, maar we anticiperen dat het werk van de K.U.Leuven de vooropgestelde einddatum van het CORNETTO project (31 maart 2008) zal overschrijden en vragen daarom een extensie van 6 maanden voor het CORNETTO project. De K.U.Leuven heeft intussen een

Nederlandstalige onderzoeker aangeworven voor het CORNETTO-project en heeft onlangs het onderzoek aangevat.

1.5 Disseminatie van resultaten (publicaties, lezingen....)

Papers

Vossen, P., Hofmann, K., de Rijke, M., Tjong Kim Sang, E., and Deschacht, K. (2007). The Cornetto Database: Architecture and User-Scenarios. In DIR 2007, pp. 89-96. ([PDF](#)) Publically available on external Website

Vossen P. and C. Fellbaum, 2007 (fc) "Universals and Idiosyncracies in Multilingual WordNets", In: Handbook Multilingual Lexicography, [Oxford University Press](#), 2007

Fellbaum C. and P. Vossen, 2007 "Connecting the Universal to the Specific: Towards the Global Grid", In: Proceedings of [The First International Workshop on Intercultural Collaboration](#) (IWIC 2007), Kyoto, Japan, January 25-26, 2007 Publically available on external Website

Vossen, P. (2006). *Cornetto: Een lexicaal-semantische database voor taaltechnologie*, Dixit Special Issue, Stevin. ([PDF](#)) Publically available on external Website

Vossen, P. (2006). *Een communicatief lexicon door het verankeren van woordbetekenissen*, Oratie. ([PDF](#)) Publically available on external Website

Posters

Hofmann, K. and Tjong Kim Sang, E. (2007). Automatic Extension of Non-English WordNets. SigIR 2007, accepted. Publically available on external Website

Talks

Tjong Kim Sang, E.: "Extracting Dutch Hypernymy Pairs from the Web". Presented at CLIN-17, 12 January 2007 in Leuven, Belgium. Publically available on external Website

Vossen, P., Maks, I., Martin, W., van der Vliet, H., Hofmann, K., van Zutphen, H.: *The Cornetto Database*. Presented at CLIN-17, 12 January 2007 in Leuven. ([Abstract](#), [PDF](#), [PowerPoint](#)) Publically available on external Website

Vossen, P.: *Een communicatief lexicon door het verankeren van woordbetekenissen*, Oratie. Presented December 22 2006 at Vrije Universiteit, Amsterdam. ([PDF](#), [PowerPoint](#)) Publically available on external Website

Vossen, P.: *Er kan meer dan men doet met de Cornetto database*. Presented November 30 2006 at the TST Themadag: de gebruiker centraal in Rotterdam. ([PDF](#), [PowerPoint](#)) Publically available on external Website

Vossen, P.: *Cornetto*. Presented September 11 2006 at the Stevin project day in Antwerp. ([PDF](#), [PowerPoint](#)) Publically available on external Website

2 Vorderingen per deliverable

2.1 Gerealiseerde werkzaamheden in afgelopen periode

WP0: Management

In de tweede periode hebben we 2 algemene projectbijeenkomsten gehad:

- 12 oktober 2006, VU, Amsterdam
- 05 januari 2007, VU Amsterdam

Daarnaast zijn er vele technische bijeenkomsten geweest tussen de projectpartners.

WP1: Cornetto database

De oplevering van de Cornetto database heeft vertraging opgelopen door problemen met betrekking tot de stabiliteit van de database en doordat de structuur van de database enige keren moest worden aangepast. De oorspronkelijke deadline voor het afmaken van de database (30 september 2006) kon daarom niet worden gehaald. Gedurende de daarop volgende zes maanden is er doorgewerkt aan de databasesoftware en zijn de nieuwe versies door de gebruikers (lexiconeditors) getest. In juni 2007 was de database stabiel genoeg voor de gebruikers om mee te werken.

WP2: Aligning semantic resources

De alignment van het Referentie Bestand Nederlands en het Nederlandse Wordnet is in deze periode uitontwikkeld. Er zijn 8 heuristieken ontwikkeld die door een team van 8 reviewers zijn bekeken. Voor iedere heuristiek is een sample van 100 woordbetekenissen aangemaakt. All reviewers hebben alle alignments geevalueerd. Deze evaluatie heeft geleid tot een calibrering van de heuristieken. Uiteindelijke data zijn gegenereerd met de meest waarwaarschijnlijke matching en mindere matches als alternatief. Op grond van de alignment zijn ook de datastructuren voor de imports gemaakt met verwijzingen naar alignments.

WP3: Ontologize

Literatuurstudie en discussies met experts gevoerd over de relatie tussen lexicon en ontologie. Dit heeft geleid tot een model voor de relatie tussen drie paradigma's van betekenis: lexicale units, synsets en typen in de ontologie. Uiteindelijk wordt alle betekenis verankerd in de ontologie maar wel wordt een onderscheid gemaakt tussen meer rigide concepten in de

ontologie en gelexicaliseerde conceptualizeringen die in het lexicon worden gedefinieerd. Deze positie is gepubliceerd in een oratie van Vossen en in twee papers van Vossen in samenwerking met Fellbaum.

WP4: Cornetto editing

- o evaluatie van 'automatic alignment'

Resultaten van het automatic alignment zijn steekproefgewijs bekeken en er is een overzicht gemaakt van probleemgevallen (probleemgevallen zijn bijv. sterk polyseme woorden in het algemeen, woorden met een groot verschil in synsets vs. lexical units; enz.). Dit heeft geleid tot de selectie van een drietal editing taken.

- o selectie editing-taken

Gekozen is voor a) het bewerken van hoog frequente werkwoorden; b) het bewerken van adjectiva; c) het bewerken van nomina met reguliere polysemie (semantic shifts). Deze groepen zijn gekozen omdat de automatic alignment bij deze gevallen niet foutloos is en omdat het om groepen woorden gaat die interessant zijn voor de toepassingen van Cornetto.

- o literatuurstudie, theoretische onderbouwing en opstellen van editing guidelines voor met name bovenstaande gevallen.

- o starten daadwerkelijke uitvoering editing

- o testen database en editor + opstellen lijsten van wensen voor veranderingen en aanpassingen

Bij het uitvoeren van de editing zijn kleinere en grotere mankementen van de editor geconstateerd; deze zijn verzameld, beschreven en er zijn suggesties voor verbeteringen gedaan.

- o planning en voorbereiding voor opname van multiword units in Cornetto

Multiword units komen voor als onderdeel van de lexical units. Bekeken is hoe een selectie van de multiword units (MWUs) zo in Cornetto opgenomen kan worden dat zij via semantische links aan een synset en via de synset aan de ontologie gekoppeld kunnen worden. In oktober is er een bijeenkomst geweest met het Stevinproject Irme, te Utrecht, om de resultaten van beide projecten af te stemmen, m.b.t. MWUs. In principe bevatten beide projecten complementaire informatie. Omdat het Irme project al in de afrondingsfase zit is er besloten om bij het ontwerp van de structuur van MWUs in Cornetto te kijken hoe gekoppeld kan worden aan Irme.

WP5: Acquisition toolkit

We hebben ons in deze periode geconcentreerd op het automatisch afleiden van hyperniemrelaties waarmee nieuwe woorden op de juiste plek in een bestaand lexicon kunnen worden geplaatst. Hiervoor hebben we gekeken naar de woorden die in een tekst in de buurt van deze nieuwe woorden voorkomen. Als bronmateriaal hebben we zowel een krantencorpus als het web gebruikt.

Dit onderzoek heeft geleid tot drie wetenschappelijke publicaties (conferenties ACL, CLIN en SIGIR) en tot software voor het afleiden van de relaties. De software kan worden gebruikt voor het afleiden van nieuwe, gerelateerde concepten.

WP6: Domain acquisition

Nog geen werkzaamheden uitgevoerd (zie boven).

WP7: Evaluation

Voor dit werkpakket (opleverdatum 30 september 2007) hebben we tot nu toe alleen aan de planning gewerkt. Hiervoor hebben we mogelijke gebruiksscenario's in kaart gebracht, zowel in algemene zin als vanuit de bestaande toepassingen binnen het consortium. Hierover zijn presentaties gegeven en een publicatie.

UAMS zal de evaluatie op twee manieren uitvoeren. Eerst zullen de woordrelaties uit Cornetto worden toegevoegd aan het zoekmechanisme van de online Verkiezingskijkerdemo. Gekeken zal worden of het uitbreiden van queries met synoniemen en hyperniemen van zoektermen, de zoekresultaten verbeterd. Daarna zullen deze relaties worden toegevoegd aan het vraag-antwoordsysteem van UAMS. Ook hier zal gekeken worden of het beschikbaar zijn van synoniemen en hyperniemen, de antwoorden van het systeem verbetert. IRION zal zich beperken tot het verbeteren van de classificatiesoftware. Er wordt gekeken of de huidige bag-of-words kan worden omgezet in combinaties van woorden en in expansies van concepten op grond van relaties uit de database. Dit moet leiden tot betere recall (expansies) en dus minder trainingsdata en tot betere precisie (woord-combinaties in plaats van losse woorden).

WP8: Distribution

Van Dale heeft het licentiecontract getekend. Het contract is nu doorgegeven aan de Universiteit van Amsterdam ter goedkeuring en tekening.

2.2 Knelpunten en oplossingen

- Geen knelpunten

2.3 Voorgestelde planning voor de komende periode

WP1: Cornetto database

De databasestructuur wordt beschouwd af te zijn. Voor de komende periode verwachten we enkel nog klein onderhoud te moeten doen in reactie op feedback van de gebruikers.

WP2: Aligning semantic resources

Automatische alignment is afgerond en data zijn geïmporteerd.

WP3: Ontologize

Verdere discussie met de makers van SUMO en ontwikkeling van een representatiemodel binnen Cornetto. Een begin wordt gemaakt met het coderen van mappings van belangrijke concepten met SUMO.

WP4: Cornetto editing

- o verder doorgaan met editing van probleemgevallen en verder uitwerken editing guidelines aan de hand van de praktijk
- o integratie van multiword units in database en editen van probleemgevallen
- o opname 'sentiment' informatie in Cornetto-database

- o theoretische onderbouwing en editing guidelines voor afstemming van ontologie en synsets

WP5: Acquisition toolkit

In de komende periode willen we de acquisitiesoftware toepassen op het juridische domeincorpus uit Leuven. Daarnaast willen we kijken of er andere woordrelaties kunnen worden afgeleid. Deze alternatieve doelrelaties zullen worden gekozen aan de hand van feedback van de lexiconeditors.

WP6: Domain acquisition

Nog niet bekend

WP7: Evaluation

UAMS wil in de komende periode relaties uit de Cornetto database toevoegen aan de Verkiezingskijkerdemo en het vraag-antwoordsysteem, en vervolgens de invloed van deze extra data evalueren. Voor IRION geldt iets dergelijks voor de classificatiesoftware. Het is op dit moment nog niet zeker of de integratie van RBN en DWN in de komende periode voltooid zal zijn. We hopen dat een substantieel gedeelte beschikbaar zal zijn voor de tests.

WP8: Distribution

- Zodra het licentiecontract getekend is door de UvA, kan het door worden gestuurd naar de Taalunie ter onder tekening.
- Er zijn nu al een aantal verzoeken voor test- en gebruikslicenties binnengekomen.